

# Action Recognition using 3D Point Cloud from Frequency Modulated Continuous Wave Radar Signals

윤희준<sup>o</sup>, 박지민, 김정태

이화여자대학교 전자전기공학전공

hjyoon9808@gmail.com pjm2782@ewhain.net jtkim@ewha.ac.kr

## 요 약

본 논문에서는 Frequency Modulated Continuous Wave(FMCW) 레이더 기반 3 차원 포인트 클라우드를 생성하고, Support Tensor Machine(STM)을 이용하여 객체의 동작 분류를 수행하였다. FMCW 레이더로 획득한 데이터에 3D Capon Beamforming 를 적용하여 3 차원 포인트 클라우드를 생성한 후에 연산량 감소를 위해 절반으로 subsampling 후 1 차원 데이터로 변환하였다. STM 을 적용하여 동작 구분을 수행한 결과, 82%의 정확도로 동작을 분류하였다.

## 1. 서론

다양한 센서를 이용한 객체의 행동 탐지 시스템은 가정, 병원 등의 장소에서 안전 모니터링 등을 목적으로 지속적으로 제시되어 왔다. 그중에서도 Frequency Modulated Continuous Wave(FMCW) 레이더는 주파수가 선형적으로 증가하는 신호를 지속적으로 송신하고 물체에 반사된 신호를 수신 안테나로 획득하는 레이더로, 송수신 신호를 혼합하여 레이더 센서와 객체의 거리, 속도, 각도를 추정할 수 있다.

동작 인식 분류를 위해 레이더로 획득 가능한 데이터로는 대표적으로 포인트 클라우드가 있다. 3 차원 포인트 클라우드는 객체의 거리, 두께, 높이 정보를 표현할 수 있다. FMCW 레이더는 카메라와 달리 사생활 침해 걱정 없이 모니터링이 가능하며, 라이더 등의 센서보다 저렴하다는 장점이 있다 [1].

레이더를 이용한 동작 인식 관련 기존 연구들은 micro-Doppler 정보에 기반하는 경우가 많았다 [2][3]. 하지만, 객체의 거리, 두께, 높이 정보의 3 차원 좌표를 모두 반영한 포인트 클라우드를 이용하면 동작에 따른 변화를 더 잘 반영할 수 있다는 장점이 있다 [4]. 따라서, 본 논문에서는 FMCW 레이더를 이용해 단일 객체의 3 차원 포인트 클라우드를 획득하고, 시간 정보를 반영할 수 있는 분류 알고리즘을 이용해 동작 분류를 수행하였다.

## 2. 포인트 클라우드 및 학습 데이터 생성 방법

3 차원 포인트 클라우드의 생성 알고리즘은 다음과 같다. 먼저, 레이더를 통해 획득한 데이터에 2D Capon Beamforming 을 적용하여 range-azimuth 히트맵을 생성한다. 그 후, Constant False Alarm Rate(CFAR)을 통해 객체가 위치하는 range-azimuth

정보를 추출하고, 해당 위치에서 3D Capon Beamforming 을 수행하여 range-azimuth-elevation 에 따른 파워를 구한 3 차원 히트맵을 얻는다. 해당 히트맵에서 미리 설정한 적절한 임계값 이상인 위치를 추출해 최종 3 차원 포인트 클라우드를 생성한다.

3 차원 포인트 클라우드 생성 후, 학습 연산량 감소를 위해 그림 1 과 같이 전체 frame, azimuth, elevation 위치 중 하나 걸러 하나씩 가져와 절반만을 이용하는 서브샘플링 기법을 적용하였다. 이를 통해 기존  $[60(\text{range}) \times 100(\text{azimuth}) \times 100(\text{elevation}) \times 100(\text{frame})]$  이었던 데이터의 크기를  $[60(\text{range}) \times 50(\text{azimuth}) \times 50(\text{elevation}) \times 50(\text{frame})]$ 으로 줄였다. 이렇게 각 프레임에서 생성되는 3 차원 데이터를 그림 2 와 같이 1 차원으로 재배열하고 프레임 방향으로 쌓아 최종 학습 데이터를 생성한다.




그림 1. 3 차원 포인트 클라우드의 서브샘플링 방법




그림 2. 3 차원 포인트 클라우드의 1 차원 변환 흐름도

### 3. 레이더 센서 및 실험환경

본 논문에서는 TI(Texas Instruments)사에서 제공하는 IWR6843-ODS 안테나를 사용하였다. 해당 안테나는 60GHz 와 64GHz 사이 대역폭에서 동작하며, 3 개의 TX 안테나, 4 개의 RX 안테나를 사용하여 총 12 개의 MIMO 안테나를 사용한다. 이때 프레임 간의 간격은 0.05 초이고, 방위각, 고도 각각에 대해 120°의 Field of View 를 제공한다.

실험은 의자에 앉기, 의자에서 일어나기, 걷기, 손들었다 내리기, 쪼그려 앉았다 일어나기 총 5 가지 동작을 5 초 이내에 수행하는 방식으로 이루어졌다. 레이더는 1.5m 높이에 설치되었으며, 총 11 명의 실험 참여자는 레이더 앞 0.5~2m 내에서 동작을 수행하였다. 최종적으로 340 번의 실험을 수행하여 5 가지 동작 별로 68 개의 실험 데이터를 획득하였다. 추가적으로, 방위각 방향으로 뒤집기를 진행하여 최종적으로 각 동작에 대해 136 개의 데이터를 생성하였다. 생성된 3 차원 포인트 클라우드의 예시는 그림 3, 4 와 같다. 그림 3 에서 볼 수 있듯이, 걷기 데이터의 포인트 클라우드에서 움직임에 따라 range 와 azimuth 가 변화하는 것을 확인할 수 있다. 또한, 그림 4 에서와 같이 쪼그려 앉기 데이터의 경우 range, azimuth 는 많이 변화하지 않지만, elevation 이 낮아졌다 객체가 일어섬에 따라 다시 증가하는 것을 볼 수 있다.

걷기 데이터

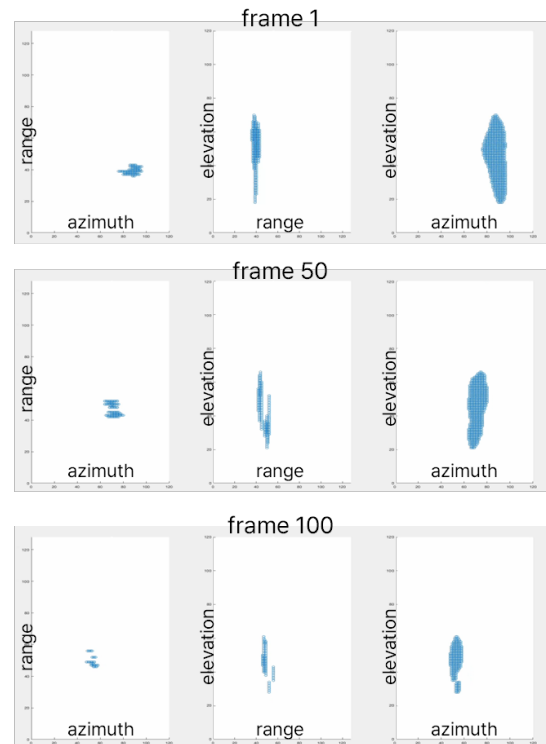


그림 3. 걷기 데이터의 포인트 클라우드 예시 영상

쪼그려 앉기 데이터

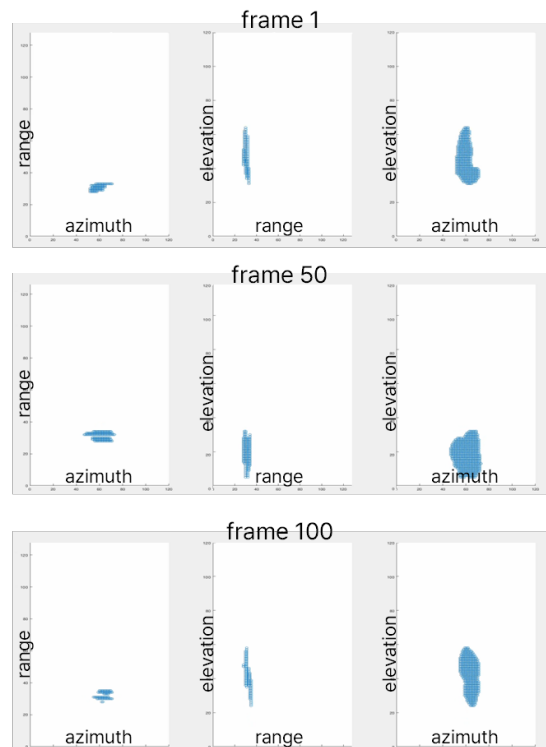


그림 4. 쪼그려 앉았다 일어나기 데이터의 포인트 클라우드 예시 영상

#### 4. Support Tensor Machine 을 이용한 실험 결과 및 분석

Support Vector Machine(SVM)은 선형이나 비선형 분류, 회귀 등 다양한 목적으로 널리 사용되는 알고리즘이다. 고차원 데이터를 1 차원 벡터로 변환하여 입력으로 넣어야 하는 기존 SVM 에서 입력을 1 차원 이상의 데이터로 넣을 수 있도록 일반화한 알고리즘이 Support Tensor Machine(STM)이다 [5]. 본 논문에서는 시간 정보의 학습 반영을 위해 시간 축을 포함한 4 차원 데이터를 1 차원으로 변환하지 않고, 시간 축을 보존한 텐서 형태로 학습을 진행하여 시간에 따른 변화를 학습하고자 하였다.

실험과 앞 절의 생성 알고리즘을 통해 생성된 총 680 개의 데이터 중 100 개의 데이터는 테스트에, 580 개의 데이터는 학습에 이용되었다. 그 결과 82%의 정확도로 동작이 분류되었으며 해당 결과의 confusion matrix 는 그림 5 와 같다. 오분류 경우를 살펴보면, 손들기 데이터를 의자에서 일어나거나 걷기 데이터로 데이터로 오분류하는 경우와 쪼그려 앉기 데이터를 의자에 앉기 데이터나 일어나기, 걷기로 오분류 하는 경우가 많았다.

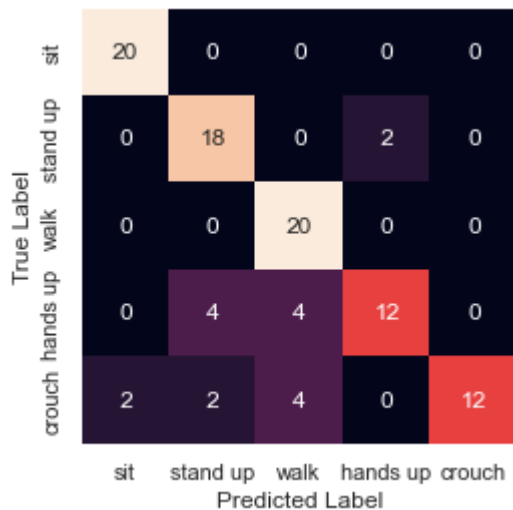


그림 5. 테스트 데이터의 confusion matrix

손들기 데이터 실험 당시 팔을 양옆으로 움직이게 되어 azimuth 방향으로 움직이는 경우가 포함되었는데, 이러한 요인이 걷기 데이터의 azimuth 방향 움직임과 혼동되어 오분류 된 것이라 추정한다. 또한, 손들기 데이터의 경우 elevation 방향으로 상승하는 데이터 경향성이 존재하는데, 이는 의자에서 일어나기 데이터도 보이는 경향성이기 때문에 오분류 원인이 된 것이라 추정한다. 추가적으로 쪼그려 앉기 데이터의 경우도 쪼그려 앉았다 일어나는 과정에서 elevation 의 변화가 일어나고, 데이터에 따라 의자에서 앉거나 일어나기 데이터로 오분류 된 것으로 추정한다.

#### 5. 결론

본 논문에서는 FMCW 레이더로 획득한 데이터를 이용하여 3 차원 포인트 클라우드를 생성하고 객체의 동작을 분류하는 연구를 수행하였다. 5 개 동작을 각 5 초간 수행하여 포인트 클라우드를 생성하고, 동작 분류를 위해 Support Tensor Machine 을 적용한 결과 총 100 개의 테스트 데이터에서 82%의 결과로 동작이 분류되었다.

#### 감사의 글

본 연구는 (주)탐중양연구소와 (주)파워로직스의 지원을 받아 수행되었습니다.

#### 참고문헌

- [1] GURBUZ, Sevgi Zubeyde; AMIN, Moeness G. Radar-based human-motion recognition with deep learning: Promising applications for indoor monitoring. IEEE Signal Processing Magazine, 2019, 36.4: 16-28.
- [2] KIM, Youngwook; LING, Hao. Human activity classification based on micro-Doppler signatures using a support vector machine. IEEE transactions on geoscience and remote sensing, 2009, 47.5: 1328-1337.
- [3] FAIRCHILD, Dustin P.; NARAYANAN, Ram M. Classification of human motions using empirical mode decomposition of human micro-Doppler signatures. IET Radar, Sonar & Navigation, 2014, 8.5: 425-434.
- [4] KIM, Youngwook; ALNUJAIM, Ibrahim; OH, Daegun. Human activity classification based on point clouds measured by millimeter wave MIMO radar with deep recurrent neural networks. IEEE Sensors Journal, 2021, 21.12: 13522-13529.
- [5] CHEN, Cong, et al. A support tensor train machine. In: 2019 International Joint Conference on Neural Networks (IJCNN). IEEE, 2019. p. 1-8.